

从“能生成文件”到“可验证交付”

Galen 无界面真实模型闭环测试可视化报告

PASS

DeepSeek V4 Pro 已完成真实闭环

18 / 18 硬门通过




一次任务如何成为 Galen 内可预览的研究交付物



01 / PERFORMANCE

两次真实 Pro 探针：响应快，闭环稳定

相同场景、相同模型与工具合同；每次使用独立临时工作区。



02 / DELIVERY CONTRACT

闭环不是一条文件路径，而是一组可验证关系

探针同时检查持久化状态、领域事件、节点归属与前端预览契约。



18 项硬门矩阵

OK 运行完成	OK 模型请求≤6	OK 工具调用≤8	OK 工具零错误	OK 聊天零错误	OK 最终响应非空
OK 无重复循环	OK 创建计划	OK 写入文件	OK 文件非空	OK Artifact 已登记	OK 任务/节点已绑定
OK ≥3 个节点	OK ≥1 节点完成	OK 双向引用一致	OK 任务事件	OK 产物事件	OK 预览格式支持

结论 本轮证明的不只是“模型写出了文件”，而是 Galen 已能把文件转换成可恢复、可追踪、可归属、可预览的科研交付物。

03 / DECISION

测试结果如何指导下一轮 Galen 优化

把真实模型探针放在单元测试之上，把鼠标验收降为发布前冒烟。

新的测试金字塔



本轮给出的三个信号

- 01

150 秒不是模型固有启动时间

无界面 TTFR 为 0.44-1.19 秒，应继续排查 UI 会话恢复、上下文装配或事件投影。
- 02

执行链已经收敛

两次都只调用 create_research_plan 与 write_file，没有重复工具或人工干预。
- 03

上下文仍是成本重点

输入约 10.5k Token。下一轮应以减少 20%-30% 为候选目标，但必须守住 18 项硬门。

下一轮实验协议

每个版本至少 5 次真实运行；采用 A-B-B-A 交错；18 项硬门必须全过；TTFR P90 不得恶化超过 10%；只有总耗时或 Token 改善 ≥15% 才升级基线。