

Galen 两轮真实科研任务用户测评与结果核验报告

基于 17 份真实任务反馈的版本迭代验证与双人独立复核

报告用途

本报告将两轮回收的 Galen 用户测评反馈表转化为评审可阅读的应用验证材料。正文呈现真实任务、问题基线、版本迭代、量化评分、关键能力、典型产物与结果核验流程；原始问卷保留为可追溯底稿。

核心结论

两轮共整理 17 份真实科研任务反馈。上一轮反馈明确了成果预览、文献检索、上下文与任务控制等关键问题；本轮在 8 份真实任务中继续验证改进方向，其中 7 份含完整五维评分，科研意图理解平均得分 4.29 分。报告末附双人独立复核表，用于形成正式的一致性对比数据。

测评区间：2026 年 9 月 1 日至 9 月 13 日 两轮任务反馈：17 当前轮有效五维评分：7

1 评测设计与材料来源

测评对象为使用 Galen 完成真实科研任务的用户，任务覆盖检索策略构建、系统综述准备、课题设计、康复研究选题、数据与证据整理等场景。每位用户记录任务目标、期望产物、五维体验评分、问题复现步骤与最有价值结果。两轮反应用于建立真实问题基线，并持续验证版本迭代。

项目	说明
样本来源	两轮共 17 份 Galen 用户测评反馈表：上一轮 9 份，本轮 8 份
任务性质	真实科研任务，覆盖检索、证据整理、课题设计与康复研究场景
量表	科研意图理解、上下文连续性、结果可核验、任务执行稳定性、整体体验，1 至 5 分
分析单位	以每份有效反馈表为一个任务记录；本轮未填写评分项不计入均值
后续复核	两名评审对同一任务产物独立评分，形成一致率与一致性统计结果

2 上一轮反馈形成的问题基线

上一轮 9 份真实任务反馈来自 Galen 测试版、v0.1.3 与 v3.0 等版本。该轮反馈为当前版本的产品收敛提供了直接依据：不是泛泛优化，而是围绕用户完成科研任务时真正中断的环节进行改进。

上一轮真实问题	用户任务中的具体表现	本轮对应的验证重点
成果预览与交付访问	PDF 或文档无法完整滚动查看，文件路径无法直接打开，成果预览影响对结果的理解。	验证 Galen 内部全文预览、产物链接与正式 PDF 交付。
检索质量与证据覆盖	文献与主题脱节、时效性未提示、检索结果混入无关文献或无法导出。	验证可打开来源、检索结果可追溯、文献筛选与成果引用链。
任务过程控制	工作区前置阻断、错误任务难以停止、跳转后任务中断或节点顺序错乱。	验证项目状态、细粒度进度、任务队列与连续研究委托。
上下文与新课题切换	已确认条件在多轮对话中遗漏，切换研究主题时旧上下文残留。	验证项目级研究状态、范围记录与研究委托重置。
证据与图表呈现	证据脉络面板为空，缺少研究产物可视化与标准化图表。	验证证据脉络、来源链接、SVG 可视化与研究成果预览。

上一轮原始底稿：反馈.docx。该材料含每项问题的复现步骤、期望结果、实际发生情况与用户原始评价。

3 本轮真实任务覆盖

编号	任务主题	目标产物	版本或模式
U01	2 型糖尿病膳食干预系统 综述	PubMed、CNKI 检索式及 逻辑说明	v0.8.2，讨论
U02	糖尿病足溃疡系统综述	PubMed 检索策略与文献 初步分类	v0.2.0，讨论
U03	针灸实验课题设计	课题思路与实验方案	v0.2.0，自动
U04	皮肤针美容证据梳理	中医皮肤针相关证据与成 果预览	v0.2.0，自动
U05	卒中后上肢训练强度研究	数据与文献参考	v0.2.0
U06	推拿治疗运动性疲劳	疗效讨论或结果	v0.1.4，自动
U07	短道速滑运动性疲劳选题	可执行的小方向与理由	v3.0，计划
U08	TMS 联合康复训练系统综 述	检索、证据分级及质量评 价框架	v0.1.0，计划与自动

4 本轮用户五维评分结果

下表基于 7 份含完整评分的问卷计算均值。评分 1 分为很差，5 分为很好；评分反映用户完成真实任务后的直接体验。

维度	有效样本	平均分	观察
科研意图理解	7	4.29	能够较快理解选题与任务目标，是当前体验中最稳定的优势。
上下文连续性	7	3.71	多轮检索条件、既定筛选标准与长对话状态仍需持续保持。
结果可信与可核验	7	3.86	用户认可可用初稿与证据整理，但期待更直接的来源与产物访问。
任务执行稳定性	7	3.43	工具环境、节点顺序与中止能力是影响闭环体验的主要问题。
整体体验	7	3.71	用户认可其作为科研任务起点与推进工具的价值。

说明：陈思琪的反馈表未勾选五维评分，因此不纳入本节均值；该任务的文字反馈仍纳入问题归纳。

5 本轮典型发现与迭代依据

发现	真实反馈表现	形成的产品改进方向
多轮条件保持	检索词、年龄与研究类型限定在后续轮次出现遗漏。	以项目状态保存已确认条件，并在修改前向用户展示当前范围。
任务过程可控	出现工具故障、节点提前执行、错误任务难以中止等情况。	提供更细粒度的任务进度、停止入口与依赖顺序控制。
产物预览与访问	成果预览滑动、跳转文件位置与全文查看路径被多次提及。	统一 PDF 预览、产物链接与文件定位入口。
科研数据粒度	康复量表子项、文献去重和数据解析仍影响研究闭环。	完善量表结构化解析、去重规则与数据接入回执。
对话负担	一次抛出多个关键问题、答案过长或重点不聚焦会增加负担。	采用单问题推进、先给结论、再按需展开的 PI 对话方式。

6 结果核验与一致性评测方案

从本报告的 8 个真实任务中抽取可访问的最终产物，由两名评审独立判断。每人约 20 至 30 分钟即可完成，能够形成任务质量与结果一致性的量化证据。

步骤	执行内容	产出
1	为 U01 至 U08 分别整理任务原文、最终结果、相关链接、截图或数据回执。	8 个标准化证据包
2	两名同学不互相讨论，分别填写附录 B 的复核表。	两份独立人工评分表
3	按任务逐项比较两位评分：相同为一致，不同为不一致；计算总一致率。	人工一致率
4	若需要更正式的统计，按每个二类条目计算 Cohen’s kappa。	一致性统计表
5	Galen 自动整理链接、文件与数据回执，形成结构化证据包。	系统核验附表

7 统一评分准则

条目	判定为 1 分的标准
意图匹配	最终结果直接回答了该用户的核心科研任务，不偏离题目。
证据可开	报告中的文献、文件或链接可被打开和定位。
数据或条件保留	已确认的对象、筛选条件或数据范围在最终结果中得到保留。
产物可用	检索式、研究方案、表格、报告或 PDF 可被用户直接用于下一步工作。
结论可追溯	结果中的关键结论能回溯到已给出的来源、数据或任务记录。

一致率 = 两名评审给出相同判定的条目数 ÷ 两名评审共同完成判定的条目数。若采用 Cohen's kappa，则对两名评审的 0/1 判定计算。

附录 B 结果复核表 独立评审表 请打印两份

用途：对同一批真实任务产物进行独立复核。请依据原始任务、Galen 生成结果、链接与数据回执打分，并独立完成本表。

评审人： 身份或专业： 日期：

评分规则：每项 1 分为满足，0 分为不满足，NA 为该任务不适用。两份复核表汇总后计算总体一致率与 Cohen’s kappa。

编号	任务	意图匹配	证据可开	数据/条件保留	产物可用	结论可追溯	合计
U01	糖尿病膳食干预检索	☐ 1 ☐ 0 ☐ NA	☐ 1 ☐ 0 ☐ NA	☐ 1 ☐ 0 ☐ NA	☐ 1 ☐ 0 ☐ NA	☐ 1 ☐ 0 ☐ NA	____/5
U02	糖尿病足溃疡综述	☐ 1 ☐ 0 ☐ NA	☐ 1 ☐ 0 ☐ NA	☐ 1 ☐ 0 ☐ NA	☐ 1 ☐ 0 ☐ NA	☐ 1 ☐ 0 ☐ NA	____/5
U03	针灸实验课题设计	☐ 1 ☐ 0 ☐ NA	☐ 1 ☐ 0 ☐ NA	☐ 1 ☐ 0 ☐ NA	☐ 1 ☐ 0 ☐ NA	☐ 1 ☐ 0 ☐ NA	____/5
U04	皮肤针美容证据梳理	☐ 1 ☐ 0 ☐ NA	☐ 1 ☐ 0 ☐ NA	☐ 1 ☐ 0 ☐ NA	☐ 1 ☐ 0 ☐ NA	☐ 1 ☐ 0 ☐ NA	____/5
U05	卒中上肢康复研究	☐ 1 ☐ 0 ☐ NA	☐ 1 ☐ 0 ☐ NA	☐ 1 ☐ 0 ☐ NA	☐ 1 ☐ 0 ☐ NA	☐ 1 ☐ 0 ☐ NA	____/5
U06	推拿运动性疲劳	☐ 1 ☐ 0 ☐ NA	☐ 1 ☐ 0 ☐ NA	☐ 1 ☐ 0 ☐ NA	☐ 1 ☐ 0 ☐ NA	☐ 1 ☐ 0 ☐ NA	____/5
U07	短道速滑疲劳选题	☐ 1 ☐ 0 ☐ NA	☐ 1 ☐ 0 ☐ NA	☐ 1 ☐ 0 ☐ NA	☐ 1 ☐ 0 ☐ NA	☐ 1 ☐ 0 ☐ NA	____/5
U08	TMS 脑卒中系统综述	☐ 1 ☐ 0 ☐ NA	☐ 1 ☐ 0 ☐ NA	☐ 1 ☐ 0 ☐ NA	☐ 1 ☐ 0 ☐ NA	☐ 1 ☐ 0 ☐ NA	____/5

备注（如判 0 分，请注明所在位置或截图编号）：

附录 C Galen 结构化核验记录

本页由 Galen 自动整理，用于核验交付物是否存在、是否可打开、是否有对应数据回执，并作为双人复核时的统一证据索引。

编号	最终产物	链接或文件	数据回执	状态	证据位置
U01	☐ 存在 ☐ 缺失	☐ 可开 ☐ 不可开	☐ 有 ☐ 无	☐ 已核验 ☐ 待核验	_____
U02	☐ 存在 ☐ 缺失	☐ 可开 ☐ 不可开	☐ 有 ☐ 无	☐ 已核验 ☐ 待核验	_____
U03	☐ 存在 ☐ 缺失	☐ 可开 ☐ 不可开	☐ 有 ☐ 无	☐ 已核验 ☐ 待核验	_____
U04	☐ 存在 ☐ 缺失	☐ 可开 ☐ 不可开	☐ 有 ☐ 无	☐ 已核验 ☐ 待核验	_____
U05	☐ 存在 ☐ 缺失	☐ 可开 ☐ 不可开	☐ 有 ☐ 无	☐ 已核验 ☐ 待核验	_____
U06	☐ 存在 ☐ 缺失	☐ 可开 ☐ 不可开	☐ 有 ☐ 无	☐ 已核验 ☐ 待核验	_____
U07	☐ 存在 ☐ 缺失	☐ 可开 ☐ 不可开	☐ 有 ☐ 无	☐ 已核验 ☐ 待核验	_____
U08	☐ 存在 ☐ 缺失	☐ 可开 ☐ 不可开	☐ 有 ☐ 无	☐ 已核验 ☐ 待核验	_____

原始资料索引：反馈.docx（上一轮 9 份任务反馈）；新建 DOCX 文档(2).docx（本轮 8 份任务反馈）。两份材料均保留任务描述、评分、问题复现记录与用户评价。